

Plan de Entrenamiento: Machine Learning y Quimioinformática con Asistencia de IA

Semana 4: Fusión de Información y Propiedades Continuas

En lugar de depender únicamente de una representación estructural o de grafos, exploraremos cómo incorporar propiedades fisicoquímicas continuas al modelo hiperdimensional.

La Semana 4 tiene las siguientes actividades: extracción de propiedades continuas de las moléculas, codificación de estos valores numéricos en hipervectores, fusión de estas representaciones con los hipervectores estructurales, y la evaluación de impacto en el rendimiento predictivo.

El resultado esperado es un clasificador HDC combinado (al estilo HDB-Combo) que supere las capacidades del modelo base implementado en la Semana 3.

- Emiliano trabajará en fusionar ECFP con las propiedades fisicoquímicas de las moléculas.
- Alexia trabajará en aprendizaje adaptivo para otorgar diferentes pesos a los hipervectores.

Material de Lectura Recomendado

1. **HDBind (Jones et al., 2024):** Repasar específicamente la sección sobre el modelo *HDB-Combo* y cómo fusionan representaciones. [Enlace al artículo](#)
2. **RDKit Descriptores:** Documentación sobre cálculo de propiedades como TPSA, peso molecular y estimaciones de polarizabilidad.
3. **Level-Hypervectors en HDC:** Material de referencia sobre cómo la computación hiperdimensional maneja valores escalares continuos asegurando que valores similares tengan vectores correlacionados (Level-HVs o Fractional Binding).
4. **Slides de contexto:** Revisar la sección de `HDC_Thesis_Background_Slides.md` pertinente a la fusión de representaciones e inyección de descriptores.

Tareas

Tarea 1: Extracción de Propiedades Continuas

Objetivo: Obtener un conjunto de descriptores numéricos que capturen características globales de las moléculas, más allá de los fragmentos capturados por ECFP.

- **Acción del Estudiante:**

1. Utilizar el mismo dataset de la Semana 3 (BBBP o BACE).
 2. Mediante RDKit (`rdkit.Chem.rdMolDescriptors`), calcular para cada molécula al menos la **polarizabilidad** estimada, el peso molecular (MW) y el coeficiente de partición (LogP).
 3. Añadir estas nuevas variables continuas como columnas al **DataFrame** existente.
 4. Normalizar estos valores numéricos (por ejemplo, escalar entre 0 y 1 o usar `StandardScaler`) para facilitar su posterior codificación.
-

Tarea 2: Codificación de Valores Continuos (Level HVs)

Objetivo: Aprender a transformar variables reales y continuas al espacio hiperdimensional, preservando la noción de distancia.

- **Concepto:** A diferencia de las características categóricas, dos valores continuos cercanos (ej. $MW = 250$ y $MW = 251$) deben mapear a hipervectores altamente similares, mientras que valores distantes deben mapear a hipervectores casi ortogonales.
 - **Acción del Estudiante:**
 1. Implementar un mecanismo de *Level-Hypervectors*. Una forma común es discretizar el rango de la variable en N niveles y generar una secuencia de hipervectores donde cada nivel cambie un porcentaje gradual de bits respecto al nivel anterior.
 2. Alternativamente, se puede utilizar proyección aleatoria adaptada para características continuas (ej. interpolación).
 3. Codificar la polarizabilidad (y opcionalmente las demás propiedades calculadas) de cada molécula en un único hipervector de propiedades $\mathbf{h}_{prop}$, de dimensión $D = 10000$.
-

Tarea 3: Fusión de Representaciones

Objetivo: Combinar la representación topológica/estructural con la representación fisico-química en un único vector de molécula.

- **Concepto:** La fusión se logra operando matemáticamente los hipervectores.

- *Bundling* (Suma): útil para acumular características (superposición). Requiere binarizar el resultado por mayoría (majority rule) si los vectores originales son bipolares.
- *Binding* (XOR o multiplicación elemento a elemento): útil para asociar pares de conceptos (crea un vector ortogonal a los originales).

- **Acción del Estudiante:**

1. Generar el hipervector estructural $\mathbf{h}_{struct}$ usando ECFP (igual que en la Semana 3).
 2. Tomar el hipervector continuo $\mathbf{h}_{prop}$ generado en la Tarea 2.
 3. Construir el vector final de la molécula $\mathbf{h}_{combo}$ fusionando ambos. Se recomienda probar primero con *Binding*: $\mathbf{h}_{combo} = \mathbf{h}_{struct} \otimes \mathbf{h}_{prop}$.
 4. Probar el enfoque de *Bundling*: $\mathbf{h}_{combo} = \text{sign}(\mathbf{h}_{struct} + \mathbf{h}_{prop})$.
-

Tarea 4: Evaluación y Comparación

Objetivo: Determinar si la inyección de propiedades fisicoquímicas mejora la capacidad predictiva.

- **Acción del Estudiante:**

1. Entrenar un clasificador por prototipos utilizando los nuevos hipervectores combinados $\mathbf{h}_{combo}$ (sumar los vectores de entrenamiento por clase).
 2. Clasificar el conjunto de test.
 3. Calcular las métricas: ROC-AUC, Accuracy y F1-score.
 4. Actualizar la tabla comparativa de la Semana 3 incluyendo esta nueva fila de resultados (ej. “HDC Combo (ECFP + Polarizabilidad)”).
 5. Analizar: ¿Mejoraron las métricas? ¿Ayudó la adición de la polarizabilidad a discriminar moléculas difíciles?
-

Consejos para trabajar con Agentes IA en esta etapa

- **Algoritmo de Level-Hypervectors:** Pide al agente que genere el código para crear un “diccionario de Level-Hypervectors”. Explícale claramente: “Necesito una función en Python que reciba un rango de valores normalizados de 0 a 1 y genere vectores bipolares de 10000 dimensiones, donde vectores contiguos cambien un subconjunto de bits proporcionales a la distancia”.

- **Depuración de Dimensiones:** Es muy fácil equivocarse en las dimensiones al hacer *Bundling* o *Binding*. Pide al modelo que inserte `assert` en el código para verificar que la dimensión de los hipervectores siempre sea $D = 10000$.
- **Comparación de operaciones:** Puedes pedir al agente que escriba una prueba unitaria para calcular la similitud coseno entre los vectores antes y después del *Binding* para entender cómo cambian.