

Plan de Entrenamiento: Machine Learning y Quimioinformatica con Asistencia de IA

Semana 3: Pipeline comun de HDC molecular

Este documento describe la tercera etapa del recorrido de aprendizaje. En las semanas anteriores se trabajaron las bases de Machine Learning molecular, representaciones quimicas, ECFP, HDBind y GraphHD. El objetivo de esta semana es pasar de la reproduccion de trabajos existentes a la construccion de un **pipeline minimo propio**.

La Semana 3 tiene las siguientes actividades: carga de datasets, generacion de fingerprints, splits, clasificador HDC, metricas y reproducibilidad.

El resultado esperado de la semana es un primer sistema ejecutable que permita comparar un baseline clasico de ML contra un baseline HDC sobre un dataset molecular simple.

Material de Lectura Recomendado

1. **Slides de contexto de las tesis:** `HDC_Thesis_Background_Slides.md`, especialmente las partes sobre HDBind, fusion de informacion, attention y topological data analysis.
2. **HDBind:** *HDBind: encoding of molecular structure with hyperdimensional binary representations* (Jones et al., 2024). [Enlace al articulo](#)
3. **MoleculeNet:** *MoleculeNet: a benchmark for molecular machine learning* (Wu et al., 2018). [Enlace al articulo](#)
4. **RDKit Morgan Fingerprints:** documentacion oficial de RDKit sobre fingerprints circulares. [Documentacion](#)
5. **Persistence Images:** *Persistence Images: A Stable Vector Representation of Persistent Homology* (Adams et al., 2017), lectura exploratoria para la linea de topologia. [Enlace al paper](#)
6. An Introduction to Johnson–Lindenstrauss Transforms -[arxc](#)

Tareas

Tarea 1: Definir el dataset comun de trabajo

Objetivo: Establecer una base experimental compartida para ambas tesis.

- **Dataset recomendado:** BBBP o BACE de MoleculeNet.
 - **Accion del Estudiante:**
 1. Cargar el dataset elegido usando DeepChem, MoleculeNet, un archivo .csv descargado o una fuente equivalente.
 2. Construir un DataFrame con al menos estas columnas:
 - smiles
 - label
 - mol_id o indice de muestra
 3. Eliminar o registrar moléculas inválidas que RDKit no pueda parsear.
 4. Hacer un split inicial train/test. En esta semana puede ser random split (siempre seteando la semilla en 42); en semanas posteriores se deberá migrar a scaffold split.
-

Tarea 2: Baseline clasico con ECFP

Objetivo: Tener una referencia no-HDC contra la cual comparar el clasificador hiperdimensional (creo que esto ya lo hicimos en una semana anterior, pero por las dudas).

- **Concepto:** Antes de evaluar HDC, es necesario saber que rendimiento obtiene un modelo tradicional usando la representación química más común: Morgan/ECFP.
 - **Accion del Estudiante:**
 1. Usar RDKit para generar Morgan fingerprints con parámetros iniciales:
 - radio = 2
 - bits = 1024
 2. Entrenar al menos un clasificador clásico:
 - LogisticRegression, o
 - RandomForestClassifier
 3. Reportar métricas:
 - ROC-AUC
 - Accuracy
 - F1-score
 4. Guardar una tabla de resultados con dataset, split, modelo, parámetros y métricas.
 - **Resultado:** Una primera línea base para comparar contra el modelo HDC.
-

Tarea 3: Implementar un baseline HDC minimo sobre ECFP

Objetivo: Construir el primer clasificador HDC propio del proyecto.

- **Concepto:** El baseline HDC debe transformar cada molecula en un hipervector y clasificar por similitud contra prototipos de clase.
 - **Accion del Estudiante:**
 1. Convertir el fingerprint ECFP binario a una representacion bipolar:
 - bit 0 -> -1
 - bit 1 -> +1 (podría ser binario, pero creo que es mejor bipolar)
 2. Vamos a trabajar con $D=10000$ (dimensión de los hipervectores), por lo que no será necesario aplicar una proyección para mapear de los 1024 a 10000 (Johnson-Lindenstrauss Theorem dice que posmultiplicar por una matriz aleatoria preserva distancias con alta probabilidad). O sea, fijamos una matriz aleatoria $R \in \{-1, 1\}^{1024 \times 10000}$, posmultiplicamos los vectores por ella y el resultante es el hipervector a utilizar. El teorema de Johnson-Lindenstrauss dice que en la nueva dimension se preservan las distancias con alta probabilidad.
 3. Construir prototipos por clase:
 - sumar los hipervectores de entrenamiento de la clase 0
 - sumar los hipervectores de entrenamiento de la clase 1
 4. Clasificar cada molecula de test por cosine similarity contra los prototipos.
 5. Evaluar ROC-AUC, accuracy y F1-score.
-

Tarea 4: Comparacion comun de resultados

Objetivo: Verificar si el pipeline experimental esta funcionando de manera razonable.

- **Accion del Estudiante:**
 1. Crear una tabla comparativa con al menos estas filas:
 - ECFP + Logistic Regression
 - ECFP + Random Forest, si fue implementado
 - ECFP + HDC prototype classifier
 2. Incluir los parametros principales:
 - dataset
 - tipo de split
 - cantidad de bits ECFP
 - dimension HDC

- semilla aleatoria
- 3. Escribir una breve interpretacion:
 - cual modelo rindio mejor
 - si los resultados parecen estables
 - que problemas tecnicos aparecieron
- **Resultado:** Una primera evidencia empirica de que el pipeline comun esta listo para extenderse.

Criterio de exito

La Semana 3 se considera completa si, al finalizar, ambos estudiantes pueden ejecutar un pipeline minimo que tome molculas en SMILES y produzca una prediccion de propiedad molecular usando:

1. un modelo clasico con ECFP, y
 2. un clasificador HDC por prototipos.
-

Consejos para trabajar con Agentes AI en esta etapa

- **Pedir implementaciones pequenas:** En lugar de pedir “implementa toda mi tesis”, pedir “escribe una funcion que reciba una lista de SMILES y devuelva Morgan fingerprints de 1024 bits”.
- **Exigir reproducibilidad:** Pedir siempre que el agente fije semillas aleatorias en `numpy`, `scikit-learn` y cualquier libreria usada.
- **Separar ciencia de codigo:** Si una funcion da error, primero pedir al agente que explique el error tecnico. Luego preguntar si el procedimiento cientifico sigue siendo valido.
- **Guardar resultados:** Pedir que cada experimento guarde una fila en un `.csv` con parametros y metricas.
- **Verificar quimica basica:** Confirmar que RDKit pudo parsear las molculas y registrar cuantas fueron descartadas.