

Plan de Entrenamiento: Machine Learning y Quimioinformática con Asistencia de IA

Semana 1

Este documento describe un recorrido de aprendizaje diseñado para estudiantes que trabajarán en la intersección de la inteligencia artificial y la química. El objetivo es construir una base sólida en Machine Learning (ML) tradicional antes de avanzar hacia enfoques de Computación Hiperdimensional (HDC).

Los estudiantes utilizarán **agentes de programación** (como Claude, GPT-4, etc.) para implementar el código, por lo que el énfasis está en la **comprensión conceptual** y la **capacidad de dirigir a la IA**.

Material de Lectura Recomendado

1. SMILES Strings [si]: [Wikipedia - SMILES](#)
2. TUDataset [si]: [Graphs for Machine Learning \(MUTAG, NCI1, etc.\)](#)
3. RDKit [opcional]: [Introducción a la biblioteca de quimioinformática](#)
4. Scikit-Learn [opcional]: [Guía oficial sobre Clasificación](#)
5. ECFP (Morgan Fingerprints) [opcional]: [Understanding Morgan Fingerprints](#)

Tareas de Entrenamiento

Tarea 1: Adquisición y Preparación de Datos

Objetivo: Leer y entender la estructura de un dataset químico clásico. * **Dataset:** Descargar o cargar mediante biblioteca (ej: `torch_geometric` o `dgl`) el dataset **MUTAG** o **NCI1** de la colección TUDataset. * **Acción del Estudiante:** Pedir al agente de programación que escriba un script para convertir estos grafos en una lista de moléculas en formato SMILES. * **Resultado:** Un DataFrame de Pandas donde cada fila sea una molécula y su respectiva clase (ej: 0 = No mutagénico, 1 = Mutagénico).

Tarea 2: Ingeniería de Características (Descriptores)

Objetivo: Generar descriptores para las moléculas. * **Concepto:** Los modelos de ML necesitan números para trabajar. Usaremos descriptores fisicoquímicos básicos. * **Acción del Estudiante:** Solicitar al agente que, usando **RDKit**, calcule los siguientes valores para cada molécula: 1. Masa Molecular (MolWt) 2. LogP (Reparto octanol/agua) 3. Aceptores y Donadores de Puentes de Hidrógeno. 4. Número de Enlaces Rotables. * **Resultado:** Un dataset de entrenamiento donde cada molécula tiene ahora 4-5 descriptores numéricos.

Tarea 3: Creación de un Modelo de Clasificación

Objetivo: Entrenar un algoritmo para predecir la propiedad química. * **Acción del Estudiante:** 1. Pedir al agente que realice un “Train/Test Split” (80% entrenamiento, 20% prueba). 2. Entrenar un modelo de **Random Forest** o **SVM (Support Vector Machine)** utilizando los descriptores de la Tarea 2. * **Resultado:** Un modelo capaz de predecir la clase de moléculas que no ha visto antes.

Tarea 4: Evaluación y Análisis de Resultados

Objetivo: Medir la calidad del modelo de forma científica. * **Acción del Estudiante:** Pedir al agente que genere un reporte de evaluación que incluya las siguientes métricas: 1. **Matriz de Confusión**. 2. **Accuracy** (Precisión global). 3. **F1-Score** (Balance entre precisión y exhaustividad). 4. **Curva ROC-AUC**. * **Desafío:** ¿Qué tan bueno es el modelo usando solo 5 números para describir moléculas complejas? (Probablemente pobre; esto motiva la Tarea 5). Aquí es importante aprender cómo se evalúa un modelo de clasificación (buscar bibliografía). Entender cada métrica.

Tarea 5: El Estándar de Oro - ECFP

Objetivo: Implementar Representaciones de Conectividad Extendida (ECFP). * **Concepto:** Aprender sobre “Morgan Fingerprints”. Son vectores binarios que codifican la presencia de subestructuras moleculares. * **Acción del Estudiante:** 1. Investigar qué significa el “radio” y el “número de bits” en un Morgan Fingerprint. 2. Pedir al agente que calcule Morgan Fingerprints (Radio=2, Bits=1024) para el mismo dataset. 3. Entrenar un nuevo modelo con estos vectores binarios. 4. Comparar el ROC-AUC de este modelo contra el modelo de descriptores de la Tarea 3. * **Resultado:** Una tabla comparativa que demuestre por qué la representación vectorial es superior a los descriptores aislados.

Consejos para trabajar con Agentes AI

- **Sé específico:** En lugar de “haz un modelo de ML”, di “Usa scikit-learn para entrenar un RandomForestClassifier con 100 estimadores y calcula la matriz de confusión”.
- **Pregunta “Por qué”:** Si el agente usa una función que no conoces, pídele que explique los parámetros matemático-químicos involucrados.
- **Verifica lógicamente:** El agente puede inventar descriptores si no eres cuidadoso; siempre consulta la documentación de RDKit.