

Plan de Entrenamiento: Machine Learning y Quimioinformática con Asistencia de IA

Semana 2: Introducción a la Computación Hiperdimensional (HDC)

Este documento describe la segunda etapa del recorrido de aprendizaje. Tras haber establecido las bases del Machine Learning tradicional aplicado a moléculas en la Semana 1, el objetivo de esta semana es introducir el paradigma de la Computación Hiperdimensional (HDC).

A lo largo de esta semana, los estudiantes leerán literatura científica clave sobre la aplicación de HDC en quimioinformática y grafos, y reproducirán los experimentos de dos repositorios de investigación: **HDBind** y **GraphHD**.

Material de Lectura Recomendado

1. **HDBind:** *HDBind: encoding of molecular structure with hyperdimensional binary representations* (Jones et al., 2024). [Enlace al artículo](#)
2. **GraphHD Original:** *GraphHD: Efficient graph classification using hyperdimensional computing* (Morris et al., 2022). [Enlace al preprint](#)
3. **GraphHD (Variantes CLEI 2025):** *Exploring Centrality Measures and Encoding Variants for Graph Classification in Hyperdimensional Computing* (Vazquez & Sica, 2025). <https://ieeexplore-ieee-org.proxy.timbo.org.uy/document/11420233>

Tareas

Tarea 1: Configuración de los Entornos de Investigación

Objetivo: Preparar el entorno computacional para ejecutar el código de los repositorios. * **Acción del Estudiante:** 1. Clonar el repositorio de **HDBind**: `git clone https://github.com/LLNL/hdbind` y consultar su README para instalar dependencias (DeepChem, PyTorch, RDKit, etc.). 2. Clonar el repositorio de **GraphHD (CLEI-2025)**: `git clone https://github.com/gustavovazquez/CLEI-2025` e instalar sus requisitos (numpy, networkx, scikit-learn, pandas).

Tarea 2: Reproducción de HDBind (Clasificación de Moléculas)

Objetivo: Ejecutar la metodología propuesta en el paper de HDBind sobre los datasets estándar de quimioinformática. * **Concepto:** HDBind codifica estructuras moleculares (como secuencias ECFP o SMILES) en vectores hiperdimensionales binarios para la predicción de propiedades. * **Acción del Estudiante:** 1. Ejecutar el script principal de entrenamiento y prueba para la base de datos MoleculeNet (ej. dataset BBBP) usando los argumentos que menciona el repositorio: `python main_molnet.py --dataset bbbp --split-type scaffold --n-trials 10 --random-state 5 --batch-size 128 --num-workers 8 --config configs/hdbind-rp-ecfp-1024-1.yml` 2. Opcionalmente, ejecutar los experimentos en la base de datos LIT-PCBA: `python main_litpcba.py --dataset lit-pcba --split-type ave --n-trials 10 --random-state 5 --batch-size 128 --num-workers 8 --config configs/hdbind-rp-ecfp-1024-1.yml` 3. Registrar el rendimiento reportado al finalizar la ejecución. * **Resultado:** Un registro empírico de que los hipervectores de HDBind son capaces de clasificar propiedades moleculares eficientemente.

Tarea 3: Reproducción de GraphHD (Clasificación de Grafos)

Objetivo: Experimentar con la clasificación de grafos enteros (como las moléculas del TU-Dataset) usando diferentes enfoques de codificación y medidas de centralidad. * **Concepto:** GraphHD clasifica grafos transformando las características de sus nodos y aristas en hipervectores mediante operaciones de *binding* y *bundling*. La variante del CLEI 2025 evalúa cómo diferentes métricas de centralidad (PageRank, Katz, etc.) impactan en el rendimiento. * **Acción del Estudiante:** 1. Ejecutar un experimento básico en el dataset **MUTAG** (el mismo de la Semana 1) usando el comando por defecto para obtener una impresión inicial: `python main.py --dataset MUTAG --n_rep 10` 2. Utilizar el script de ejecución en paralelo para replicar la comparación de la métrica de centralidad de Katz en el framework: `python benchmark_parallel.py --datasets MUTAG --metrics katz --n_rep 5 --output mutag_katz_results.csv` * **Resultado:** Archivos .csv con los resultados de clasificación (f1_mean, accuracy_mean, total_time_sec) que permiten comparar las distintas configuraciones de GraphHD.

Consejos para trabajar con Agentes AI en esta etapa

- **Explicación de código:** Si no comprendes cómo se realiza la codificación, copia un bloque de los archivos (ej. de `model.py` en HDBind o `encoders.py` en GraphHD) y pregúntale al agente: “¿Cómo implementa matemáticamente este bloque de código las operaciones de ‘bundling’ o ‘binding’ en HDC?”.